

双11背后的技术杂谈

刘文飞 2017-10-12

1111-购物狂欢节



以往11月份便是消费的淡季。暗淡的销售额令天猫的各大卖家头痛,决定创造出淡季的再一次辉煌。

从2009年到2016年,"双十一"已经从天猫扩散到全电商平台,从国内扩展到全球。11月11日,正逐渐从单一的电商营销日,变成了全球消费者的购物狂欢节,而这种扩展更是带动了整个中国商业的巨大变局。

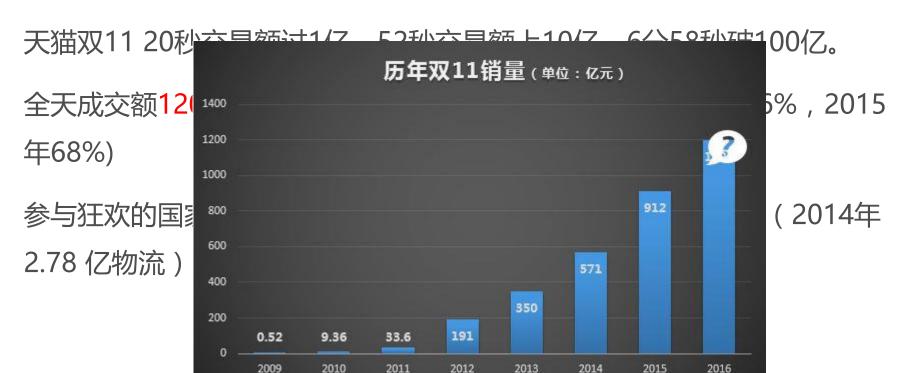
现在的1111是中国最具影响力的购物节。



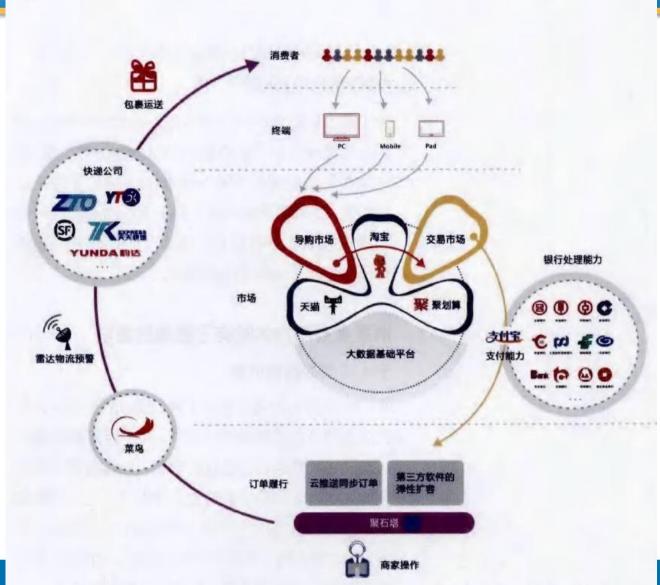
双11数据



2016年



双11业务流程





一业务的快速增长带来架构的进化

大型网站软件系统的特点

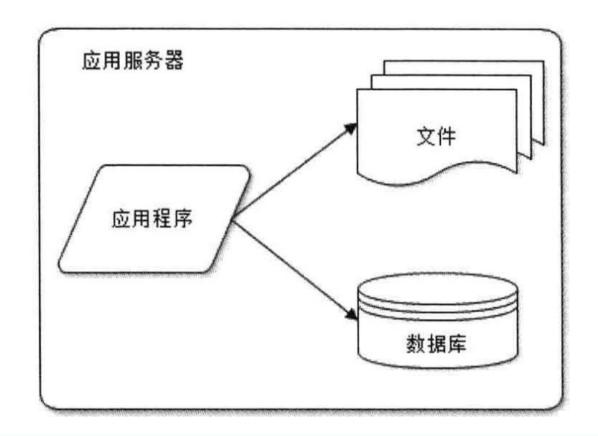


- 高并发 , 大流量
- 高可用
- 海量数据
- 用户分布广泛,网络情况复杂
- 安全环境恶劣
- 需求快速变更,发布频繁
- 渐进式发展

1初始阶段



应用程序、数据库、文件都在一台服务器,如常用的Linux+PHP+Apache+Mysql



2 应用服务和数据库分离

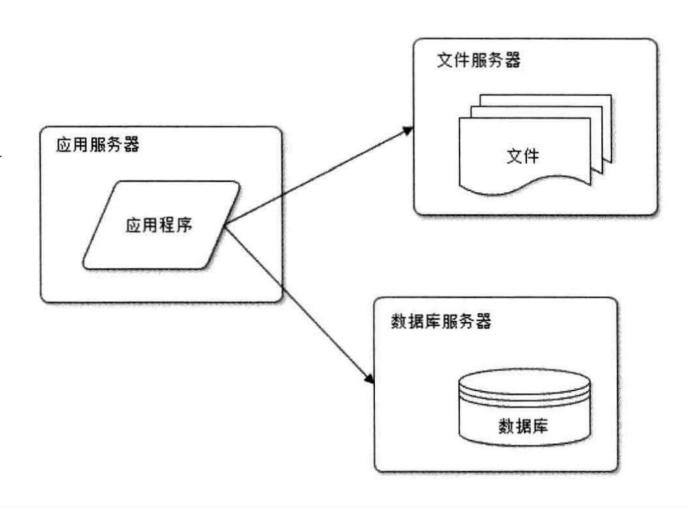


原因:性能变差、存

储空间不足

三台服务器:

应用服务器(运算能力:CPU)、文件服务器(更大的存储)和数据库服务器(更大的存储)的存储和内存)

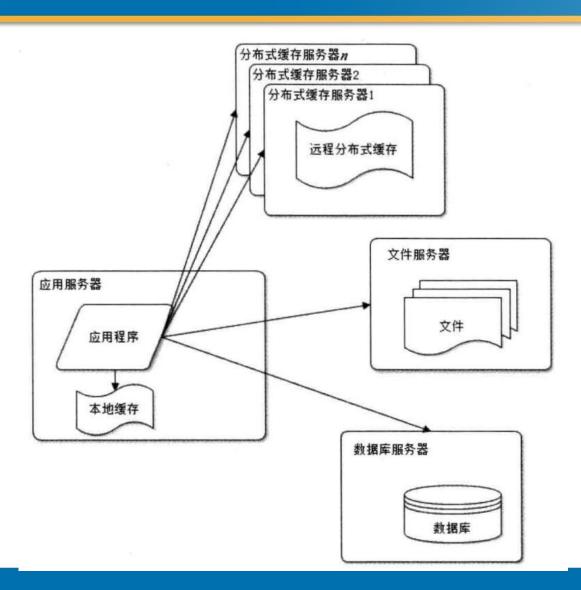


3 使用缓存改善



原因:数据库访问压力太大; 数据访问遵循2-8定律

将访问多的20%的数据放在缓存上,可分为应用服务器端的本地缓存和分布式的远端缓存

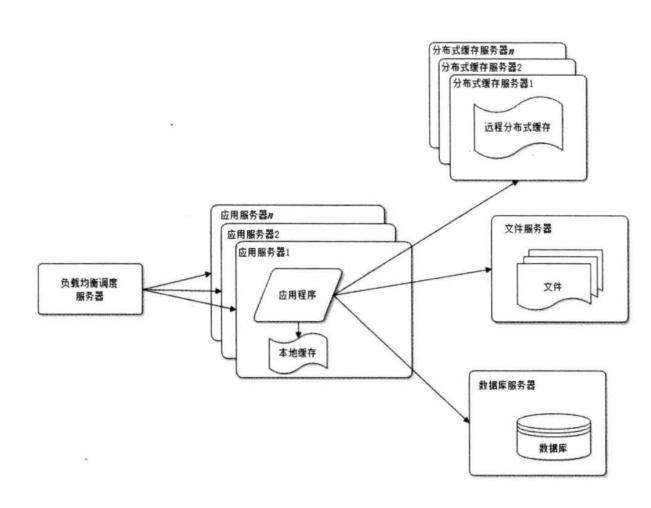


4应用服务器集群



原因:单一服务器处理的 请求链接成为瓶颈

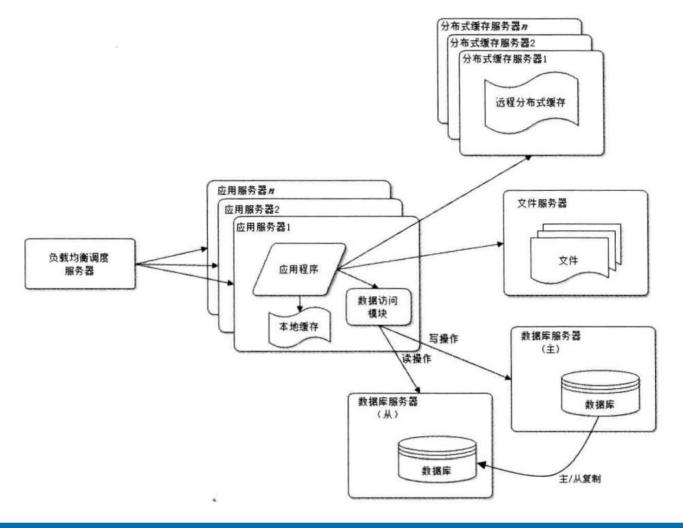
使用应用服务器集群,使 用反向代理实现负载均衡、 可用性监测、可伸缩的实 现



5 数据库读写分离

原因:使用缓存后,仍有部分读操作和全部写操作要访问数据库,随着规模的增大,这些操作造成数据库瓶颈

数据库进行主从备份和读写分离





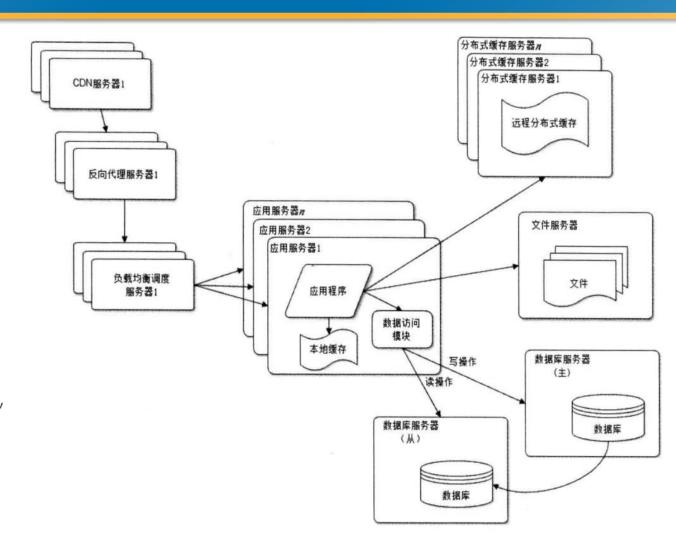
Information Retrieval Laboratory of DVI

原因:加速网站访问速度

CDN: 部署到客户端最近的 网络提供商的机房,用户可从自己最近的网络提供商获取数据,多用于静态内容如CSS、图片等

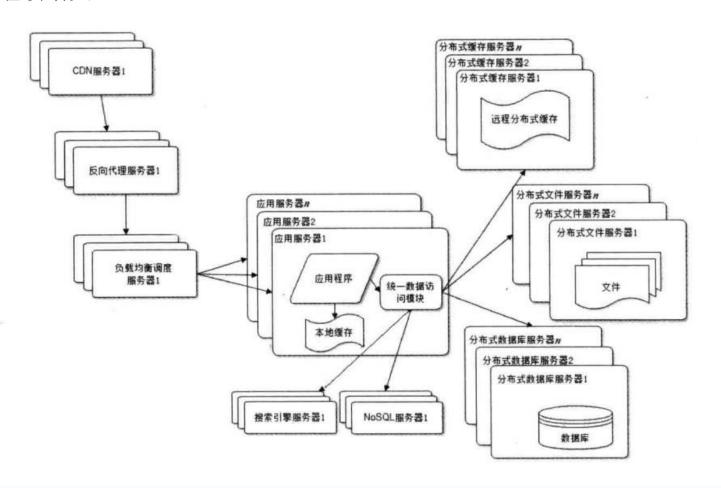
反向代理:一般代理都是在客户的浏览器端,而此处的代理是在网站端。

用户请求先通过反向代理, 反向代理如果缓存有用户 需要的资源则立刻返回, 否则调用相应服务器



7 使用分布式文件/数据库系统

原因:业务需求继续增大

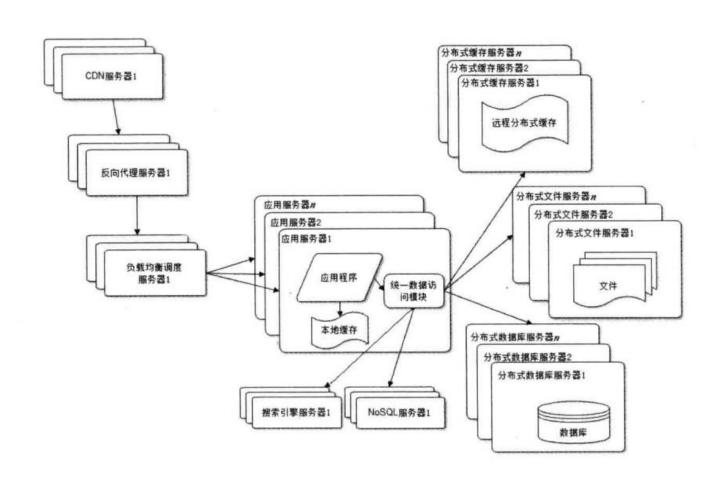


8 使用NOSQL和搜索引擎



原因:数据存储和 检索越来越复杂

NoSQL对可伸缩的 分布式特性有很好 的支持

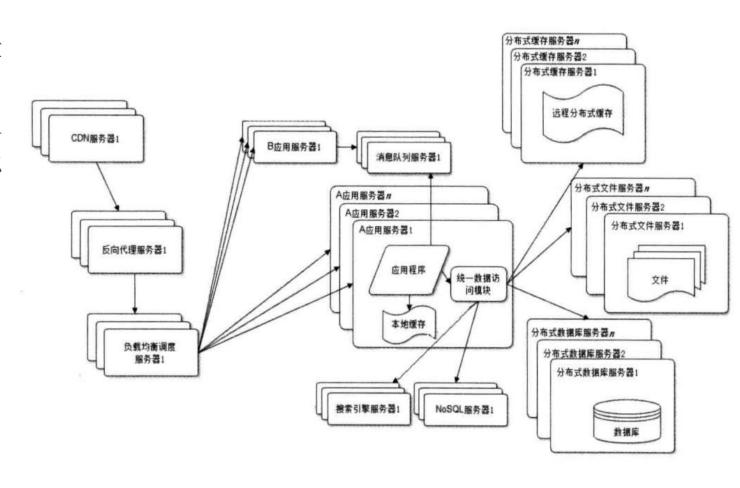


9业务拆分



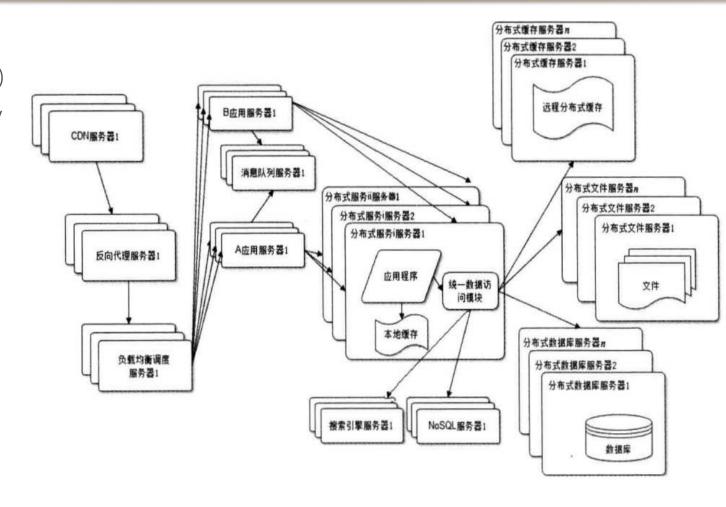
原因:网站业务 足够复杂,业务量 太大

将网站拆分成多个 应用,每个应用独 立维护



10 分布式服务

将共有业务(用户管理、商品管理等) 提取出来独立部署, 上层业务复用这些业务完成具体操作



淘宝实现网站高负载的原因



- 应用无状态(淘宝session框架)
- 有效使用缓存(Local & Remote)
- 应用拆分
- 数据库拆分(水平拆分和垂直拆分,基本没有表关联)
- 异步通信
- 非结构化数据存储
- 监控、预警系统
- 配置统一管理



二 网购秒杀系统架构设计

什么是秒杀



秒杀是电子商务网站常见的一种**营销手段**:将少量商品(通常只有一件)以极低的价格,在特定的时间点开始出售。比如一元钱的手机,五元钱的电脑,十元钱的汽车等等。因为商品价格诱人,数量有限,因此很多人趋之若鹜,**在秒 杀活动开始前涌入网站,不断刷新页面**,等到秒杀活动开始的一瞬间,点下购买按钮。



秒杀的技术挑战



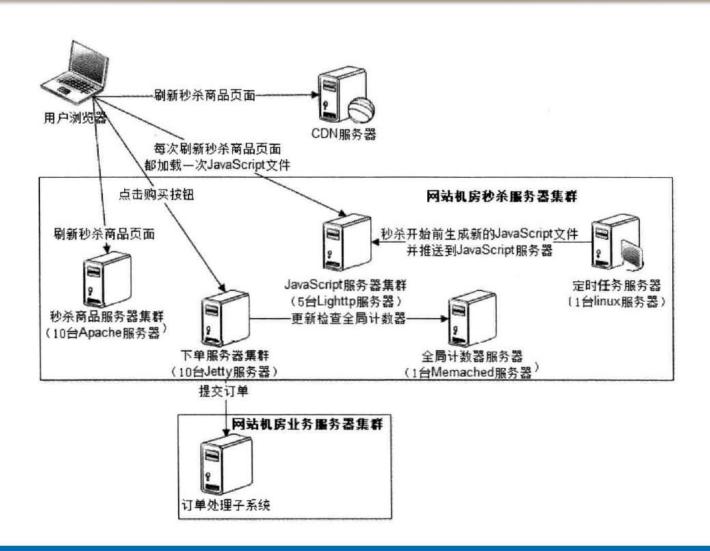
- 对现有网站业务造成冲击
- 高并发下的应用和数据库负载
- 突然增加的网络及服务器带宽
- 直接下单

秒杀系统应对策略



- 秒杀系统独立部署
- 秒杀商品页面静态化
- 租借秒杀活动网络带宽
- 动态生成随机下单页面URL

秒杀系统架构设计



秒杀系统小结



秒杀是对网站架构的极大考验,在难以预计和控制的高并 发访问的冲击下,稍微不慎,系统就会被用户秒杀。

因此在遵循秒杀活动游戏规则的前提下,尽力保证系统的 稳定安全,保持适度的公平公正即可。

即使系统出了故障,也不要给用户显示出错的信息,直接显示秒杀活动结束的页面即可,避免不必要的麻烦。



三 淘宝推荐系统

推荐系统的定义



维基百科:推荐系统属于资讯过滤的一种应用。推荐系统能够将可能受 喜好的资讯或实物(例如:电影、电视节目、音乐、书籍、新闻、图片 、网页)推荐给使用者。

推荐系统的作用



- 从用户角度:
 - ◆ 提高用户忠诚度
 - 帮助用户快速找到商品
- 从网站角度:
 - 提高网站交叉销售能力
 - 提高成交转化率

好的推荐系统更像一个有经验的网站导购员

推荐系统与其他系统的区别



• 推荐与搜索

- 相同点:帮助用户找到商品
- 不同点:搜索是通过用户主动输入的关键字进行查询。推荐则是用户在浏览网站的过程中,不一定需要用户输入,根据当前网页的上下文进行个性化的信息输出。

• 推荐与广告

- ◆ 相同点:基于用户行为
- 不同点:广告目的是帮助商家推广商品等,推荐系统帮助用户找到想要的商品等。

推荐系统的主要产品



- 同类或者相关商品、店铺推荐
- 买了还买、看了还看等。
- 猜你喜欢
- 热门排行榜
- etc

推荐系统的主要产品



- 同类或者相关商品、店铺推荐
- 买了还买、看了还看等
- 猜你喜欢
- 热门排行榜
- etc

推荐系统的组成



● 1、数据

- explicit(显式):能准确的反应用户对物品的真实喜好,但需要用户付出额 外的代价。如:用户收藏、用户评价。
- Implicit(隐式):通过一些分析和处理,才能反映用户的喜好,只是数据不是很精确,有些行为的分析存在较大的噪音。如:用户浏览、用户页面停留时间、访问次数。

• 2、算法

- 离线:用户类目偏好、用户购买力分析、关联性分析、相似矩阵计算等等
- ◆ 在线:排序、过滤、增量计算
- 算法需要配合大量业务规则,没有最好,只有更好!

• 3、消息系统

◆ 消息系统是大型系统不可或缺的重要组成部分,与其他系统解耦,消息转发。

推荐系统的组成



• 4、搜索引擎

主要功能是进行文本分析抽取关键词,作为推荐系统的一个信息检索技术内容相关性匹配。

5, NoSQL

◆ 简单、高性能、方便定制

• 6、分布式计算

使用MapReduce , Hive、Hadoop进行大规模数据统计和运算和大数据集合的ETL

推荐系统的组成



• 4、搜索引擎

主要功能是进行文本分析抽取关键词,作为推荐系统的一个信息检索技术内容相关性匹配。

5, NoSQL

◆ 简单、高性能、方便定制

● 6、分布式计算

使用MapReduce , Hive、Hadoop进行大规模数据统计和运算和大数据集合的ETL

淘宝数据的特点



- 数据量巨大:数百万店铺、数亿激活用户、数亿的在线商品、数十亿的收藏信息...
- 商品问题:同一类商品多个卖家、标类非标类、类目属性正确性、恶意 收藏、刷信誉...

淘宝推荐系统的算法



- 基础算法:聚类算法,预测算法,分类算法等,主要用于产生基础知识库
 - 预测算法: logistic 回归,通过以点击率为目标,以商品,卖家等因素作为指标,建立预测模型构建淘宝优质宝贝库
 - 分类算法: 朴素贝叶斯, 商品性别判断(男性,女性,中性),用户性别判断
 - 聚类算法:人群,用户细分,用于降维
- 推荐算法: content-based, collaborative-based, Association Rules等等

淘宝推荐系统的算法



- 基于内容推荐:通过给用户和商品标注Tag,通过内容匹配算法,推荐商品给用户
 - 优点:简单,搜索引擎支持,解决部分冷启动问题
 - ◆ 缺点:难以区分商品信息的品质,而且不能为用户发现新的感兴趣的商品,只能 发现和用户已有兴趣相似的商品
- 协同思想
 - ◆ 优点:新奇特,个性化程度高
 - 缺点:冷启动,稀疏性
- 关联规则:类目的相关性、商品相关性、人的相关性

参考资料



http://www.csdn.net/article/2013-12-23/2817882

天猫篇

- (1) 双11的前端实践
- (2) 天猫浏览型应用的CDN静态化架构演变
- (3) 个性化技术在双11的应用
- (4) 聚石塔: 电子商务云平台2013年双11历程

支付宝篇

(1) 支付宝的架构变迁

中间件篇

- (1) 中间件技术的双11实践
- (2) 软负载: 分布式系统的引路人
- (3) 分布式服务框架: 分布式服务的组织者
- (4) 消息中间件: 分布式消息的广播员





